

# Ampliación de Inferencia Estadística

## TERCERO GRADO DE ESTADÍSTICA

### UNIVERSIDAD DE SEVILLA

#### TEMA 5: INFERENCIA BAYESIANA EN EL MODELO NORMAL

#### PRÁCTICA-R-5. SEGUNDA PARTE.

### La Normal-GammaI

```
library("plot3Drgl")


## Loading required package: rgl
## Loading required package: plot3D

library(plot3D)
require(rgl)

m=10 # valor de la media
c= 1/10 # valor de la constante
a=1# primer parámetro de la gamma invertida
b=4 # segundo valor de la gamma invertida
x <- seq(m-2, m+2, length.out = 50)
y <- seq(0.11, 5, length.out = 25)
ngai <- function(x,y) {
  b^a/(gamma(a)) *(1/y^(a+1))*exp(-b/y)*(1/(sqrt(2*pi)))*exp(-(x-m)^2/(2*y*c))
}

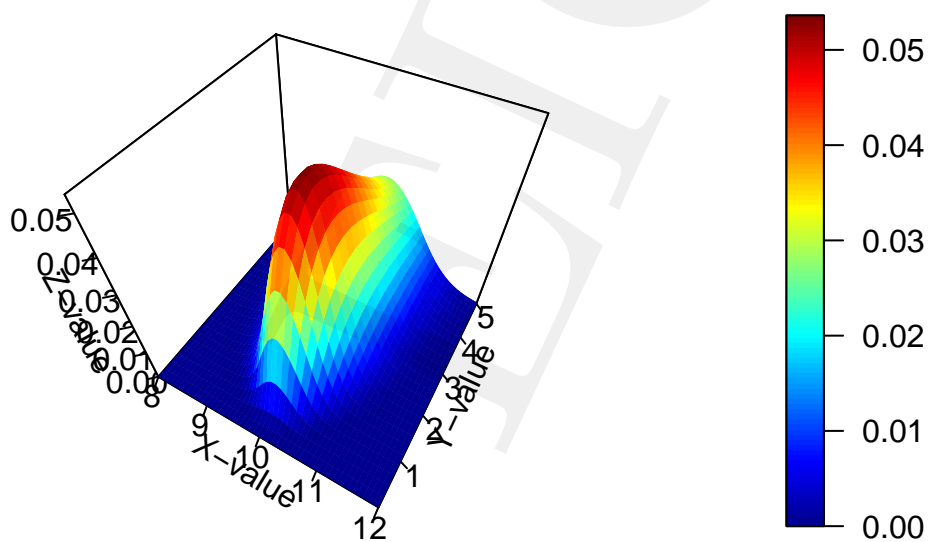
z <- outer(x, y, ngai)
persp(x, y, z,main="Perspectiva Cónica",
      zlab = "Height",
      theta = 30, phi = 15,
      col = "springgreen", shade = 0.5)
```

## Perspectiva Cónica



```
persp3D(x,y,z,theta=30, phi=50, axes=TRUE,scale=2, box=TRUE, nticks=5,  
        ticktype="detailed", xlab="X-value", ylab="Y-value", zlab="Z-value",  
        main="Normal Gamma Invertida")
```


### Normal Gamma Invertida



## Problema 1.

### LA MARATHON DE NUEVA YORK

```
library(LearnBayes)
data("marathontimes")
View(marathontimes)
attach(marathontimes)
hist(time,freq=F)
curve(dnorm(x,mean=mean(time),sd=sd(time)),add=T,col="blue")
```



```
shapiro.test(time)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  time
## W = 0.97012, p-value = 0.7573
```


```
t.test(time)
```

```
##
##  One Sample t-test
##
## data:  time
## t = 25.061, df = 19, p-value = 5.094e-16
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
```

```
## 254.4154 300.7846
## sample estimates:
## mean of x
## 277.6
```

Efecto gráfico sobre distintas curvas según posibles valores de las medias del IC.

```
hist(time,freq=F)
curve(dnorm(x,mean=255,sd=sd(time)),add=T,col="red")
curve(dnorm(x,mean=265,sd=sd(time)),add=T,col="green")
curve(dnorm(x,mean=285,sd=sd(time)),add=T,col="purple")
curve(dnorm(x,mean=300,sd=sd(time)),add=T,col="blue")
curve(dnorm(x,mean=400,sd=sd(time)),add=T,col="blue")
```



Hagamos lo mismo para la varianza

```
n=length(time)
uppert=(n-1)*sd(time)^2/qchisq(0.025,df=n-1);sqrt(uppert)

## [1] 72.35422

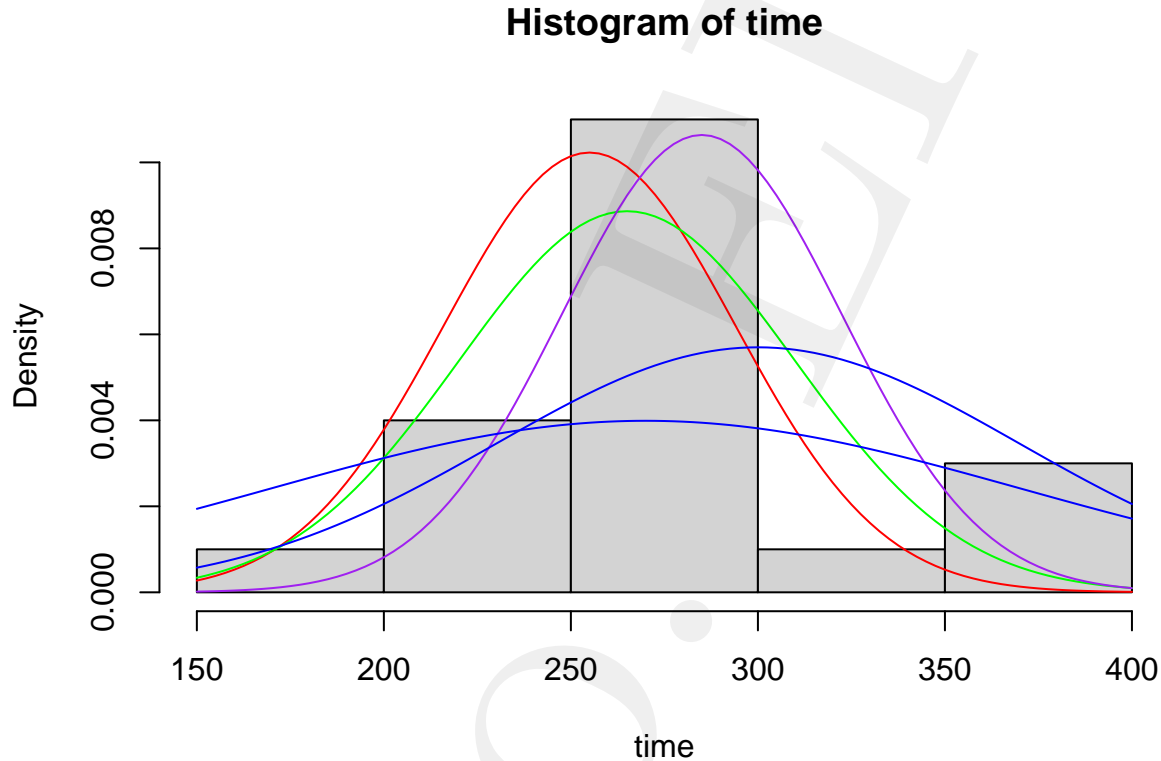
lowert=(n-1)*sd(time)^2/qchisq(0.975,df=n-1);sqrt(lowert)

## [1] 37.67339
```

Representemos curvas normales para diferentes desviaciones típicas.

```
hist(time,freq=F)
curve(dnorm(x,mean=255,sd=39),add=T,col="red")
curve(dnorm(x,mean=265,sd=45),add=T,col="green")
```

```
curve(dnorm(x,mean=285,sd=37.5),add=T,col="purple")
curve(dnorm(x,mean=300,sd=70),add=T,col="blue")
curve(dnorm(x,mean=270,sd=100),add=T,col="blue")
```



Un problema típico de inferencia consiste en estimar los parámetros desconocidos de una normal. Para ilustrar los métodos bayesianos, vamos a suponer que estamos interesados en estimar dichos parámetros en la prueba masculina de la maratón de Nueva York para edades comprendidas entre 20 y 29 años. Se observan los tiempos  $\mathbf{y} = (y_1, \dots, y_{20})$  para 20 corredores en minutos, y vamos a suponer que proceden de una población normal. Si también suponemos que no disponemos de información a priori lo sensato es proponer una distribución a priori de Jeffrey:

$$g(\mu, \sigma_2) := 1/\sigma_2^{3/2}$$

Entonces, la densidad a posteriori de la media y la varianza viene dada por

$$g(\mu, \sigma_2 | \mathbf{y}) := (1/\sigma_2)^{\frac{n+3}{2}} \exp\left[-\frac{1}{2\sigma_2}(nS^2 + n(\mu - \bar{y})^2)\right]$$

donde  $n$  es el tamaño muestral,  $\bar{y}$  es la media muestral y  $S^2$  la varianza muestral.

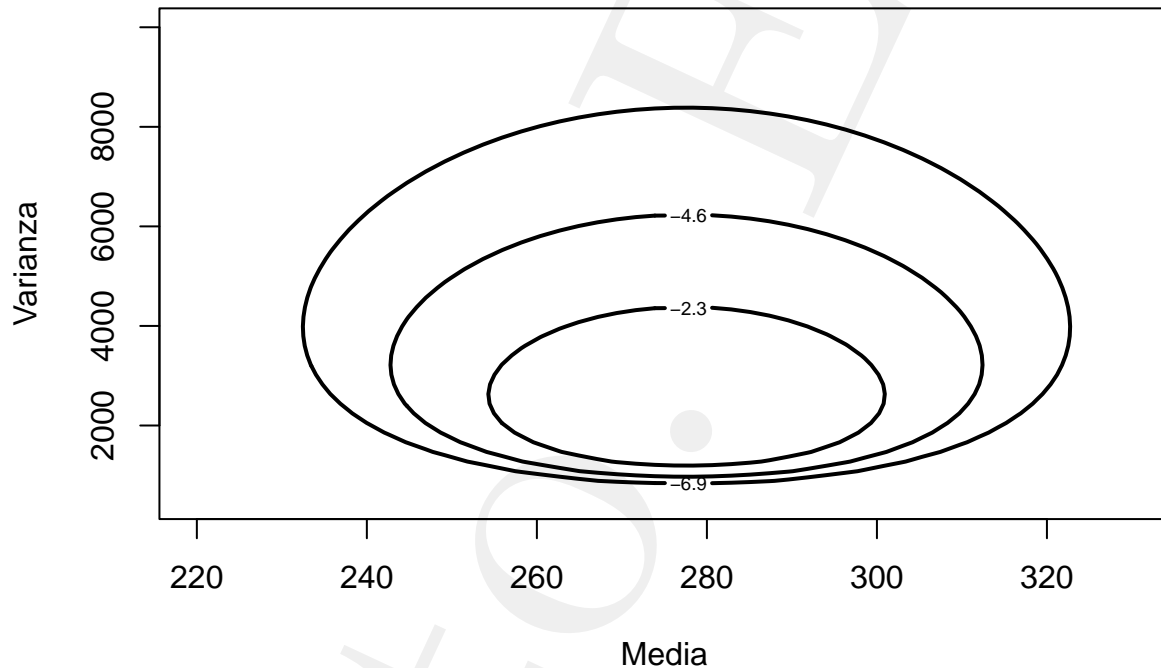
Es decir la a posteriori conjunta es una normal-gamma-invertida ya que

1. La a posteriori de  $\mu$  condicionada a  $\sigma_2$  es  $N(\bar{y}, \frac{\sigma_2}{n})$ .
2. La a posteriori de  $\sigma_2$  es una gamma invertida cuyos parámetros son:  $\frac{n}{2}$  y  $ns^2/2$ .

Primero vamos a usar R para construir un gráfico de contorno de la densidad a posteriori. La función en R `normchi2post.R` que está en `LearnBayes` calcula un algoritmo para el logaritmo de la densidad a posteriori de  $(\mu, \sigma_2)$ . También usaremos la función `mycontour.R` que facilita el uso del comando `contour`. El comando

`mycontour` tiene tres parámetros: el nombre de la función que define la densidad log, un vector con valores que definen el rectángulo donde la densidad es representada y los datos que se usan en la función para la densidad log. La función produce un contorno donde las líneas del contorno son dibujadas al 10%, 1% y 0.1% del valor máximo de la densidad a posteriori sobre la malla.

```
d=mycontour(normchi2post,c(220,330,500,10000),time)
title(xlab="Media",ylab="Varianza")
```



Es conveniente describir esta distribución a posteriori mediante técnicas de simulación. Para simular un valor de  $(\mu, \sigma_2)$  de la a posteriori conjunta, primero simulamos un valor de  $\sigma_2$  de la correspondiente gamma-invertida y luego simulamos un valor de  $\mu$  de una normal con parámetros  $(\bar{y}, \frac{\sigma_2}{n})$ . Hay que tener en cuenta que la distribución a posteriori de  $\sigma_2$  viene dada por


$$\frac{nS^2}{\sigma_2^2} \sim \chi_{n-1}^2.$$

En la siguiente salida de R, primero simulamos una muestra de tamaño 1000 de la chi-cuadrado usando la función `rchisq`. A partir de aquí se obtienen muestras de la distribución chi-cuadrada inversa escalada de la varianza  $\sigma_2$  mediante la transformación de las muestras chi-cuadrado. Por último, se obtienen muestras de la media  $\mu$  usando la función `rnorm`.

```
Su=sum((time-mean(time))^2)
n=length(time)
S=Su/(n) # Se usará más adelante
sigma2=(Su)/rchisq(1000,df=n)
mu=rnorm(1000,mean=mean(time),sd=sqrt(sigma2)/sqrt(n))
```

A continuación se muestran todos estos datos simulados en un contorno.

```
d=mycontour(normchi2post,c(220,330,500,10000),time)
title(xlab="Media",ylab="Varianza")
points(mu,sigma2)
```



Si quisiéramos obtener estimaciones de la desviación típica  $\sqrt{\sigma_2}$  que describe la dispersión de los tiempos de la Maratón debemos obtener una muestra de la a posteriori de  $\sigma_2$ , le calculamos las raíces cuadradas y obtenemos la región creíble HPDI al 90%. En este caso tendríamos

```
library(HDIInterval)
dens2 <- density(sigma2)
sqrt(hdi(dens2, credMass=0.90))
```

```
##      lower      upper
## 35.02789 62.04783
## attr("credMass")
## [1] 0.9
## attr("height")
## [1] 9.775413e-05
```

En el caso de la a priori que hemos supuesto si queremos obtener una región de credibilidad de la media tenemos que usar el resultado correspondiente a la densidad marginal a posteriori:

$$Z|\mathbf{x} \sim t_n, \text{ donde } Z = \sqrt{n} \frac{\theta - \bar{x}}{S}.$$

```
tsup=qt(0.975,n)
ss=mean(time)+tsup*sqrt(S/n)
```



```
ii=mean(time)-tsup*sqrt(S/n)  
print(c(ii,ss))
```

```
## [1] 255.0786 300.1214
```