

INFERENCIA BAYESIANA

- contenidos :
- conceptos básicos
 - aplicación a los modelos
 - modelo Beta-Binomial
 - modelo Poisson
 - modelo Normal
 - modelos multiparamétricos

1) CONCEPTOS BASICOS

Uhm : Bayes theorem

TEOREMA
DE BAYES

- Para eventos: (Ω, \mathcal{A}, P) espacio de probabilidad,
 $\{A_i\}_{i=1}^n$ sucesión de eventos con prob. no nulas
B evento de prob. no nula

$$P(A_k | B) = \frac{P(A_k) P(B | A_k)}{\sum_{i=1}^n P(A_i) P(B | A_i)} \quad \forall k = 1, \dots, n$$

- Para variables aleatorias discretas

X v.a. $\rightsquigarrow \text{Im}(X) = \{x_1, \dots, x_m\}$ \rightarrow partición $\{A_j\}_{j=1}^m$
discr.

Y v.a. $\rightsquigarrow \text{Im}(Y) = \{y_1, \dots, y_n\}$ \rightarrow partición $\{B_i\}_{i=1}^n$

$$P(Y=y_i | X=x_j) = \frac{P(Y=y_i) P(X=x_j | Y=y_i)}{\sum_{k=1}^n P(Y=y_k) P(X=x_j | Y=y_k)} \quad \begin{matrix} \forall i=1, \dots, n \\ \forall j=1, \dots, m \end{matrix}$$

$$(P(A_i) = P(\omega \in \Omega : X(\omega) = x_i) = P(X = x_i))$$

- Para variables aleatorias continuas

(X, Y) vect. aleatorio bidim. abs. cont. con

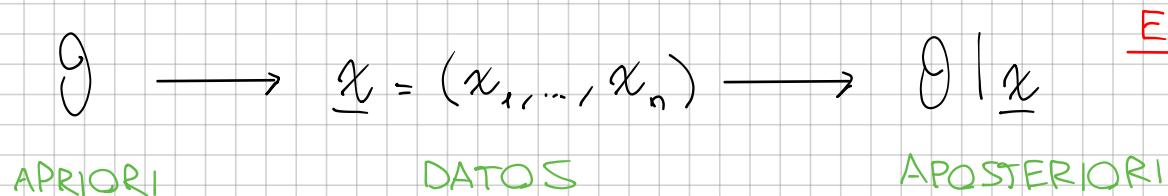
→ $f(x, y)$ función de densidad

→ h densidad marginal de X

→ g densidad marginal de Y

$$\Rightarrow f(y|x) = \frac{f(x, y)}{h(x)} = \frac{g(y) f(x|y)}{h(x)}$$

$$= \frac{g(y) f(x|y)}{\int f(x, y) dy} = \frac{g(y) f(x|y)}{\int g(y) f(x|y) dy}$$



def: $\mathcal{L} : \Theta \times \Theta \longrightarrow \mathbb{R}^+$ FUNCIÓN DE PERDIDA

~ función que cuantifica el error de estimación de $\hat{\theta}$ (ESTIMADOR) con respecto a θ

ej: • $\mathcal{L}(\hat{\theta}, \theta) = (\hat{\theta} - \theta)^2$ CUADRATICA

• $\mathcal{L}(\hat{\theta}, \theta) = |\hat{\theta} - \theta|$ norma L_1

Para demostrar los valores óptimos por las funciones de pérdida previas necesitamos un resultado preliminar

Lemma: X v.a., $X \geq 0$, $\mathbb{E}[X] < +\infty$

$$\Rightarrow \mathbb{E}[X] = \int_0^{+\infty} (1 - F_X(t)) dt$$

$$\begin{aligned} \text{dim: } \mathbb{E}[X] &= \lim_{m \rightarrow +\infty} \int_0^{+\infty} x dF(x) \stackrel{\text{IPP}}{=} \lim_{m \rightarrow +\infty} \left[x [F(x)]_0^m - \int_0^m F(x) dx \right] \\ &= \lim_{m \rightarrow +\infty} \left[m F(m) - \int_0^m F(x) dx \right] \\ &= \lim_{m \rightarrow +\infty} \left[m (F(m) - 1) + \int_0^m (1 - F(t)) dt \right] \end{aligned}$$

Ahora demostraremos que $\lim_{m \rightarrow +\infty} [m (F(m) - 1)] = 0$

$$\begin{aligned} \mathbb{E}[X] &= \lim_{m \rightarrow +\infty} \left(\int_0^m x dF(x) + \int_m^{+\infty} x dF(x) \right) \\ &\geq \lim_{m \rightarrow +\infty} \left(\int_0^m x dF(x) + m P(X \geq m) \right) \\ &= \mathbb{E}[X] + \underbrace{\lim_{m \rightarrow +\infty} m P(X \geq m)}_{= \bigcirc} \end{aligned}$$

$$\text{n.B. } m P(X \geq m) = m (1 - F(m))$$

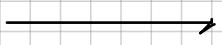
$$\Rightarrow \mathbb{E}[X] = \int_0^{+\infty} (1 - F(t)) dt \quad \square$$

prop : ESTIMADORES DE BAYES

función de pérdida

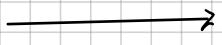
estimador

• cuadráticas



medio a posteriori

• norma L_1



mediana a posteriori

detr:

$$1) \text{ definimos } g(\bar{\theta}) = \mathbb{E}[(\theta - \bar{\theta})^2 | \underline{x}]$$

↑ estimador puntual de $\bar{\theta}$
(dependiente de los datos)

$$\rightarrow g'(\bar{\theta}) = 2 \left(\mathbb{E}[\theta | \underline{x}] - \bar{\theta} \right) = 0 \quad (\min)$$

$$\Rightarrow \bar{\theta} = \mathbb{E}[\theta | \underline{x}] \left[\begin{array}{l} \frac{\partial}{\partial \bar{\theta}} \mathbb{E}[\theta^2 | \underline{x}] \\ = 2 \left(\underbrace{\mathbb{E}[\theta | \underline{x}]}_{\bar{\theta}} - \mathbb{E}[\theta | \underline{x}] \right) \end{array} \right]$$

$$2) \mathbb{E}[|\theta - \bar{\theta}| | \underline{x}] = \int_{\bar{\theta}}^{+\infty} (1 - P(\theta \leq t | \underline{x})) dt - \int_{-\infty}^{\bar{\theta}} P(\theta \leq t | \underline{x}) dt$$

$$\hookrightarrow \frac{\partial}{\partial \bar{\theta}} \rightarrow 1 - 2P(\theta \leq \bar{\theta} | \underline{x}) = 0$$

$$\Rightarrow \bar{\theta} \text{ t.q. } P(\theta \leq \bar{\theta} | \underline{x}) = \frac{1}{2}$$

es decir $\bar{\theta} = \text{Median}(\theta | \underline{x}) \quad \square$

def: $\gamma \in (0,1)$, nivel de CREDIBILIDAD

INTERVALOS DE CREDIB.

$$(b_l, b_u) \text{ t.q. } \int_{t_l}^{t_u} f(\theta | \underline{x}) d\theta = \gamma$$

con
 $\underline{x} = (x_1, \dots, x_n)$
datos

INTERVALO DE CREDIBILIDAD (nivel γ)

métodos de cálculo:

(1) para dist. unimodales : HPDI (high posterior density interval)

→ calculamos un intervalo de prob. que contenga a la moda y t.q. cada punto de este intervalo tenga valor de prob. mayor que cualquier otro punto fuera

(2) para contener la mediana: se calcula repartiendo la misma probabilidad en las colas

(MÉTODO DE COLAS IGUAL. POND.)

(3) si la media existe, intervalo t.q. media es punto central

métodos de elección de lo apriori:

ELECCIÓN DE APRIORI

→ distribuciones conjugadas

→ distribuciones no informativas (improperas)

→ apriori de Jeffrey

def: DISTRIBUCIONES CONJUGADAS

$$L(\theta) = f(x|\theta) \text{ verosimilitud de } \theta$$

\mathcal{E} , clase de distr., se define CONJUGADA con respecto a $L(\theta)$, si para una a priori $\pi(\theta) \in \mathcal{E}$ la distr. aposterior $\pi(\theta|x) \in \mathcal{E} \quad \forall x$

Es decir, si $\pi(\theta) \in \mathcal{E} \Rightarrow \pi(\theta|x) \in \mathcal{E} \quad \forall x$

def: DISTRIBUCIONES IMPROPIAS

Una función l.g. no cumple la propiedad $\int_{\Omega} f(x) dx = 1$
se define DISTR. IMPROPIA

def: DISTRIBUCIÓN DE JEFFREY (para el caso unidimensional)

$$\pi(\theta) \propto I^{1/2}(\theta)$$

$$I(\theta) = \mathbb{E}_{\theta} \left[\left(\frac{\partial \log f(x|\theta)}{\partial \theta} \right)^2 \right]$$

INFORMACIÓN DE FISHER

INFORMACIÓN DE FISHER, APRIORI DE JEFFREY

Definición: cuantificar la información de un muestreo sobre de un parámetro que se quiere estimar

(Que entendemos cuando decimos INFORMACIÓN)

→ podemos decir que: un valor de X_0 es INFORMATIVO cerca de un valor particular del parámetro θ_0 cuando el valor de función de densidad varía mucho para un valor del parámetro muy cercano a θ_0

• informativo $\Leftrightarrow f(x|B_0) \xrightarrow{\text{baja}} f(x|\theta_0 + \delta\theta)$

Para medir la distancia entre funciones de densidad se puede usar el cociente entre funciones

$$\begin{cases} f_x(x|\theta), \theta \in \Theta \\ \theta = \theta_0 + \delta\theta \end{cases} \quad \frac{f_x(x|\theta_0)}{f_x(x|\theta_0 + \delta\theta)} = \frac{f_x(x|\theta_0)}{f_x(x|\theta)}$$

→ valor grande: A. INFORMATIVO
la función de densidad disminuye en número directamente cuando rebasamos θ_0
→ valor cerca 0: NO INFORMATIVO

Al no podemos definir la discrepancia entre las funciones de densidad:

excursus:

porque la a priori de Jeffrey?

objetivo: Dado una muestra
 $\underline{x} = (x_1, \dots, x_n)$ predecir
 $y \sim f(\cdot | \theta)$

DISTRIBUCIÓN PREDICTIVA

Hay dos maneras de calcular la distr. de y

(1) aplicando el lhm de Bayes

$$f(\theta | y, \underline{x}) = \frac{f(y | \underline{x}) f(\theta | \underline{x})}{\int f(y | \underline{x}) d\theta}$$

$$f(y | \underline{x}) = \frac{f(y | \theta, \underline{x}) \pi(\theta | \underline{x})}{\int f(y | \theta, \underline{x}) d\theta}$$

(2) ponderación con la aposteriori

$$\hat{f}(y | \underline{x}) = \int_{\Theta} f(y | \theta, \underline{x}) \pi(\theta | \underline{x}) d\theta$$

$$\begin{cases} H_0: \theta \in \Theta_0 \\ H_1: \theta \in \Theta_1 \end{cases} \quad \begin{matrix} \text{a partir de} \\ \text{una muestra } \underline{x} \end{matrix}$$

FACTORE DE BAYES

def:

$$FB_{\theta_0} = \frac{P(\underline{x} | H_0)}{P(\underline{x} | H_1)}$$

FACTOR DE BAYES

interpretación: FACTOR DE BAYES

si $FB_{01} \approx 0 \Rightarrow P(\underline{x} | H_0) \ll P(\underline{x} | H_1)$
evidencia para decir que los datos
son generados por H_1

si FB_{01} grande $\Rightarrow P(\underline{x} | H_0) \gg P(\underline{x} | H_1)$
evidencia para decir que los
datos son generados por H_0

Ahora aplicando Bayes:

$$P(\underline{x} | H_0) = \frac{P(\underline{x}) P(H_0 | \underline{x})}{P(H_0)}$$

$$P(\underline{x} | H_1) = \frac{P(\underline{x}) P(H_1 | \underline{x})}{P(H_1)}$$

→ $FB_{01} = \frac{P(H_1 | \underline{x})}{P(H_0 | \underline{x})} \cdot \frac{P(H_0)}{P(H_1)}$

2) APLICACIÓN A LOS MODELOS

MODELO BETA-BINOMIAL

datos

$$\underline{x} = (x_1, \dots, x_n) \text{ donde } x_i \in \{0, 1\} \quad \forall i$$

- Función de verosimilitud: $(X \sim \text{Be}(p))$

$$\begin{aligned} L(p | \underline{x}) &= f(\underline{x} | p) = \prod_{i=1}^n f(x_i | p) \\ &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \\ &= p^{\sum x_i} (1-p)^{n - \sum x_i} \end{aligned}$$

- Apriori \longrightarrow Apósterior;

→ NO INFORMATIVA COMPLETA: $\pi(p) = I_{[0,1]}(p)$

$$(p \sim \text{Beta}(1,1) = U_{[0,1]})$$

$$\pi(p | \underline{x}) \propto L(p | \underline{x}) \pi(p) = p^{\sum x_i} (1-p)^{n - \sum x_i}$$

$$\hookrightarrow p | \underline{x} \sim \text{Beta}\left(\sum x_i + 1, n - \sum x_i + 1\right)$$

→ APRIORI DE JEFFREY: $\pi(p) = p^{-1/2} (1-p)^{-1/2}$

Calculamos la inform. de Fisher

$$f(x|p) = p^x (1-p)^{1-x} \rightarrow \ln f(x|p) = x \ln(p) + (1-x) \ln(1-p)$$

$$\frac{\partial \ln f(x|p)}{\partial p} = \frac{x}{p} - \frac{1-x}{1-p} = \frac{x(1-p) - p(1-x)}{p(1-p)} = \frac{x-p}{p(1-p)}$$

$$\hookrightarrow I(p) = \mathbb{E} \left[\left(\frac{\partial \ln f}{\partial p} \right)^2 \right] = \frac{1}{p^2(1-p)^2} \mathbb{E} \left[(x-p)^2 \right]$$

$$= \frac{1}{p(1-p)}$$

$$\Rightarrow \pi(p) = p^{-1/2} (1-p)^{-1/2}$$

$$\Rightarrow p \sim \text{Beta} \left(\frac{1}{2}, \frac{1}{2} \right)$$

$$\Rightarrow \pi(p|x) = p^{\sum x_i - \frac{1}{2}} (1-p)^{n - \sum x_i - \frac{1}{2}}$$

$$\Rightarrow p|x \sim \text{Beta} \left(\sum x_i + \frac{1}{2}, n - \sum x_i + \frac{1}{2} \right)$$

→ PRIORI POR EL METODO DE LAS CONJUGADAS

$$p \sim \text{Beta}(\alpha, \beta)$$

$$\Rightarrow p|x \sim \text{Beta} \left(\sum x_i + \alpha + 1, n - \sum x_i + \beta + 1 \right)$$

$$p = p^{\sum x_i} (1-p)$$

- estimadores

Suponemos una p_{posterior}: $p|\underline{x} \sim \text{Beta}(a(\underline{x}), b(\underline{x}))$

Función de pérdida cuadr.: $E[p|\underline{x}] = \frac{a(\underline{x})}{a(\underline{x}) + b(\underline{x})}$

Función de perd. L_1 : $\text{Med}(p|\underline{X}) = \dots$

\hookrightarrow no calculo expl.

- distribución predictiva: $Y \sim \text{Bern}(p^*)$

$$p^* = P(Y=1 | \underline{x}) = \int_0^1 P(Y=1 | \underline{x}, p) \pi(p|\underline{x}) dp$$

$$\underset{\substack{\text{generica} \\ \text{apriori}}} = \int_0^1 p \cdot \frac{p^{\sum x_i + a - 1} (1-p)^{n - \sum x_i + b - 1}}{B(\sum x_i + a, n - \sum x_i + b)} dp$$

$$= \frac{B(\sum x_i + a + 1, n - \sum x_i + b)}{B(\sum x_i + a, n - \sum x_i + b)}$$

MODELO POISSON

$\underline{\chi} = (\chi_1, \dots, \chi_n)$ con $\chi_i \in \mathbb{N} \quad \forall i$

- función de verosimilitud

$$L(\lambda | \underline{\chi}) = \prod_{i=1}^n f(\chi_i | \lambda) = \prod_{i=1}^n e^{-\lambda} \frac{\lambda^{\chi_i}}{\chi_i!} \propto \lambda^{\sum \chi_i} e^{-n\lambda}$$

- a priori \rightarrow a posteriori:

\rightarrow APRIORI DE JEFFREY

Calculamos la información de Fisher:

$$\ln f(\chi | \lambda) = \ln \left(e^{-\lambda} \frac{\lambda^\chi}{\chi!} \right) = -\lambda + \chi \ln \lambda - \ln(\chi!)$$

$$\frac{\partial \ln f(\chi | \lambda)}{\partial \lambda} = \frac{\chi}{\lambda} - 1$$

$$\Rightarrow I(\lambda) = \mathbb{E} \left[\left(\frac{\chi - \lambda}{\lambda} \right)^2 \right] = \frac{1}{\lambda^2} \cdot \lambda = 1/\lambda$$

$$\Rightarrow \pi(\lambda) = 1/\sqrt{\lambda} = \lambda^{-1/2}$$

$$\Rightarrow \pi(\lambda | \underline{\chi}) \propto \lambda^{\sum \chi_i - 1/2} e^{-n\lambda}$$

es decir $\lambda | \underline{\chi} \sim \text{Gamma} \left(\sum \chi_i + \frac{1}{2}, n \right)$

\rightarrow APRIORI CON EL METODO DE LAS CONJUGADAS

$$\lambda \sim \text{Gamma}(\alpha, \beta)$$

$$\Rightarrow \pi(\lambda | \underline{x}) \propto \lambda^{\sum x_i - n} e^{-n\lambda} \cdot \lambda^{\alpha-1} e^{-\beta\lambda}$$

$$\propto \lambda^{\sum x_i + \alpha - 1} \cdot e^{-(n+\beta)\lambda}$$

$$\Rightarrow \lambda | \underline{x} \sim \text{Gamma}(\sum x_i + \alpha, n + \beta)$$

→ APRIORI NO INFORMATIVA COMPLETA

$$\pi(\lambda) = \int_{[0, +\infty)} (\lambda)$$

$$\Rightarrow \pi(\lambda | \underline{x}) = \lambda^{\sum x_i} e^{-n\lambda}$$

$$\Rightarrow \lambda | \underline{x} \sim \text{Gamma}(\sum x_i + 1, n)$$

- estimadores

Asumiendo como posterior: $\lambda | \underline{x} \sim \text{Gamma}(\alpha(\underline{x}), \beta(\underline{x}))$

- función de pérdida cuadr. $E[\lambda | \underline{x}] = \frac{\alpha(\underline{x})}{\beta(\underline{x})}$

- función de pérdida L₁: mediana ~ calculada con R

- distribución predictiva $\rightarrow \alpha = \alpha(\underline{x}), \beta = \beta(\underline{x})$

$Y \sim \text{Pois}(\lambda), \lambda | \underline{x} \sim \text{Gamma}(\alpha, \beta)$

$$\Rightarrow P(Y=k | \underline{x}) = \int_0^{+\infty} P(Y=k | \lambda, \underline{x}) \pi(\lambda | \underline{x}) d\lambda$$

$$= \int_0^{+\infty} e^{-\lambda} \frac{\lambda^k}{k!} \cdot \beta^\alpha \lambda^{\alpha-1} e^{-\beta\lambda} \cdot \frac{1}{\Gamma(\alpha)} d\lambda$$

$$\begin{aligned}
&= \frac{1}{k!} \beta^\alpha \cdot \frac{1}{\Gamma(\alpha)} \int_0^{+\infty} e^{-(\beta+1)\lambda} \lambda^{\alpha+k-1} d\lambda \\
&= \frac{1}{k!} \cdot \frac{\beta^\alpha}{(\beta+1)^{\alpha+k}} \cdot \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)} \quad \text{si } \alpha \in \mathbb{N} \\
&\quad \boxed{\Rightarrow = \frac{(\alpha+k-1)!}{(\alpha-1)!} = (\alpha+k-1)(\alpha+k-2) \cdots \alpha} \\
&= \frac{\binom{\alpha+k-1}{k}}{k! (\alpha-1)!} \cdot \left(\frac{\beta}{\beta+1} \right)^\alpha \left(\frac{1}{\beta+1} \right)^k
\end{aligned}$$

es decir $Y | \underline{\lambda} \sim NB\left(\frac{\beta}{\beta+1}, n\right)$

DISTRIBUCIÓN BINOMIAL NEGATIVA

$X \sim NB(p, n) \sim \begin{matrix} \text{numero de triunfos antes} \\ \text{de n intentos} \end{matrix}$

$$\begin{aligned}
P(X=k|p,n) &= \binom{k+n}{k} p^k \\
&= \binom{-n}{k} p^n (p-1)^k \\
E[X|p,n] &= \frac{n}{p}, \quad Var(X|p,n) = n \frac{(1-p)}{p^2}
\end{aligned}$$

MODELO NORMAL (varianza conocida)

$$\underline{x} = (x_1, \dots, x_n), x_i \sim N(\mu, \sigma^2) \quad \xrightarrow{\text{conocida}}$$

- Función de verosimilitud

$$L(\theta | \underline{x}) = \prod_{i=1}^n f(x_i | \mu, \sigma^2) \propto \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\}$$

$$\propto \exp \left\{ -\frac{1}{2\sigma^2} (n\bar{x}^2 - 2n\mu\bar{x}) \right\}$$

- Apriori $\xrightarrow{\text{!}}$ Aposteriori:

→ APRIORI DE JEFFREY

$$\ln f(x | \mu) = -\frac{(x - \mu)^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2)$$

$$\frac{\partial}{\partial \mu} \ln f(x | \mu) = \frac{1}{\sigma^2} (x - \mu)$$

$$\hookrightarrow I(\mu) = E \left[\frac{1}{\sigma^2} (X - \mu)^2 \right] = \frac{1}{\sigma^4} \cdot \sigma^2 = 1/\sigma^2$$

$$\Rightarrow \pi(\mu) = 1/\sigma \quad \rightsquigarrow \text{CONSTANTE: coincide con una no informativa comp.}$$

$$\Rightarrow \pi(\mu | \underline{x}) \propto \exp \left\{ -\frac{1}{2\sigma^2} (n\bar{x}^2 - 2n\mu\bar{x}) \right\}$$

$$\Rightarrow \mu | \underline{x} \sim N(\bar{x}, \frac{\sigma^2}{n})$$

→ APRIORI CON EL MÉTODO DE LA CONJUGADAS

Esto claro que la clase de distribuciones conjugadas a la función de verosimilitud es la de las normales

Por eso, $\mu \sim N(\mu_0, \sigma_0^2)$

$$\Rightarrow \pi(\mu | \underline{x}) \propto \exp \left\{ -\frac{1}{2\sigma^2} \left(n\mu^2 - 2n\mu\bar{x} \right) \right\} \exp \left\{ -\frac{1}{2\sigma_0^2} \left(\mu^2 - 2\mu_0\mu \right) \right\}$$

$$\propto \exp \left\{ -\frac{1}{2} \left(\mu^2 \left(\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2} \right) - 2\mu \left(\frac{n}{\sigma^2} \bar{x} + \frac{1}{\sigma_0^2} \mu_0 \right) \right) \right\}$$

$$\Rightarrow \mu | \underline{x} \sim N \left(\frac{n\bar{x} + \frac{1}{\sigma^2} \mu_0}{\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}}, \frac{\sigma_0^2 \sigma^2}{\frac{n}{\sigma^2} + \frac{1}{\sigma_0^2}} \right)$$

- estimadores y intervalos de credibilidad

Asumiendo como a posteriori $\mu | \underline{x} \sim N(\mu_p, \sigma_p^2)$

$$\hat{\mu}_B = \mu_p \quad \begin{pmatrix} \text{para las funciones de pérdida cuadr.} \\ \text{y } L^+, \text{ Normal es simétrica} \end{pmatrix}$$

Intervalo de credibilidad

$$IC(\mu, 1-\alpha) = \mu_p \pm z_{1-\frac{\alpha}{2}} \cdot \sigma_p$$

- distribución predictiva

$$Y \sim N(\mu, \sigma^2) \rightarrow \text{nueva obs. iid}$$

$$f(y|x) = \int_{-\infty}^{+\infty} f(y|\mu, x) \pi(\mu|x) d\mu$$

para calcularlo usamos la función generatriz de momentos

$$\begin{aligned}
 m_{y|x}(t) &= \int_{-\infty}^{+\infty} e^{ty} f(y|x) dy \\
 &= \int_{-\infty}^{+\infty} e^{ty} \left[\int_{-\infty}^{+\infty} f(y|\mu, x) \pi(\mu|x) d\mu \right] dy \\
 &\stackrel{\text{FCB(N)} \quad \text{TONELLI}}{=} \int_{-\infty}^{+\infty} \pi(\mu|x) \left[\int_{-\infty}^{+\infty} e^{ty} f(y|\mu, x) dy \right] d\mu \\
 &= \int_{-\infty}^{+\infty} \pi(\mu|x) m_{y|\mu}(t) d\mu \\
 &= \int_{-\infty}^{+\infty} \pi(\mu|x) \exp \left\{ \mu t + \frac{t^2 \sigma_p^2}{2} \right\} d\mu \\
 &= e^{\frac{t^2 \sigma_p^2}{2}} \int_{-\infty}^{+\infty} \pi(\mu|x) e^{\mu t} d\mu = m_{\mu|x}(t) \\
 &= e^{\frac{t^2 \sigma_p^2}{2}} \cdot e^{\mu_p t + \frac{1}{2} \sigma_p^2 t^2} = m_{y|x}(t)
 \end{aligned}$$

$$\Rightarrow y|x \sim N(\mu_p, b^2 + \sigma_p^2)$$

MODELO NORMAL (varianza desconocida)

- Función de verosimilitud

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\}$$

$$L(\mu, \sigma^2 | \underline{x}) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}$$

notación:

$$\begin{array}{ccc} \mu & \longleftrightarrow & \theta \\ \sigma^2 & \longleftrightarrow & \phi \end{array}$$

$$\begin{aligned} &= \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - \mu)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + 2(\bar{x} - \mu) \sum_{i=1}^n (x_i - \bar{x}) \\ &\quad + n(\bar{x} - \mu)^2 \end{aligned}$$

$$L(\theta, \phi | \underline{x}) = (2\pi\phi)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\phi} \left((n-1) \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2 \right) \right\}$$

- Apriori \longrightarrow Apósterior:

$$I(\theta, \phi) = \begin{pmatrix} -\mathbb{E}\left[\frac{\partial^2}{\partial \theta^2} \log f(x | \theta, \phi)\right] & -\mathbb{E}\left[\frac{\partial^2}{\partial \theta \partial \phi} \log f(x | \theta, \phi)\right] \\ -\mathbb{E}\left[\frac{\partial^2}{\partial \phi \partial \theta} \log f(x | \theta, \phi)\right] & -\mathbb{E}\left[\frac{\partial^2}{\partial \phi^2} \log f(x | \theta, \phi)\right] \end{pmatrix}$$

$$(\log f(x | \theta, \phi)) = -\frac{(x - \theta)^2}{2\phi} - \frac{1}{2} \log(2\pi\phi)$$

APRIORI DE
JEFFREY

$$\frac{\partial^2}{\partial \theta^2} \log f(x | \theta, \phi) = \frac{\partial}{\partial \theta} \left[\frac{(x - \theta)}{\phi} \right] = -\frac{1}{\phi}$$

$$\frac{\partial^2}{\partial \phi \partial \theta} \log f(x | \theta, \phi) = \frac{\partial}{\partial \phi} \left[\frac{(x - \theta)}{\phi} \right] = -\frac{(x - \theta)}{\phi^2}$$

$$\bullet \frac{\partial^2}{\partial \phi^2} \log f(x|\theta, \phi) = \frac{\partial}{\partial \phi} \left[\frac{(x-\theta)^2}{2\phi^2} - \frac{\pi}{\phi} \right] = -\frac{(x-\theta)^2}{\phi^3}$$

$$= \begin{pmatrix} 1/\phi & 0 \\ 0 & \frac{1}{\phi^2} (n-1) \end{pmatrix} + \frac{\pi}{\phi}$$

$$\Rightarrow \pi(\theta, \phi) \propto \sqrt{\det I(\theta, \phi)}$$

$$\propto \phi^{-3/2}$$

$$\Rightarrow \pi(\theta, \phi | \underline{x}) \propto \phi^{-\frac{1}{2}(n+3)} \exp \left\{ -\frac{1}{2\phi} (n-1) \sum \exp \left\{ -\frac{n(\theta-\bar{x})^2}{2\phi} \right\} \right\}$$

$$\propto \phi^{-(\frac{n}{2}+1)} \exp \left\{ -\frac{1}{2\phi} (n-1) \sum \left\{ \phi^{-\frac{1}{2}} \exp \left\{ -\frac{n(\theta-\bar{x})^2}{2\phi} \right\} \right\} \right\}$$

$$\bullet \theta | \underline{x} \sim N(\bar{x}, \phi/n)$$

$$\bullet \phi | \underline{x}, \sim G\alpha I \left(\frac{n}{2}, \frac{(n-1)S^2}{2} \right)$$

GAMMA-INVERTIDA $X \sim G\alpha I(\alpha, \lambda)$

$$f(x | \alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \cdot \frac{1}{x^{\alpha+1}} e^{-\lambda/x} \quad \forall x > 0, \alpha > 0, \lambda > 0$$

prop: $\frac{1}{X} \sim G\alpha I(\alpha, \lambda)$

$$\Rightarrow E[X] = \frac{\lambda}{\alpha+1}, \text{Var}(X) = \frac{\lambda^2}{(\alpha+1)^2(\alpha+2)}$$

$$\text{med}(X) = \frac{\lambda}{\alpha+1}$$

$$\hookrightarrow (\theta, \phi) | \underline{x} \sim N(G\alpha I \left(\bar{x}, \frac{1}{n}, \frac{n}{2}, \frac{(n-1)S^2}{2} \right))$$

Dprob : MARGINALES

$$\rightarrow \textcircled{1} | \underline{x} \sim G\alpha I \left(\frac{n}{2}, \frac{(n-1)S^2}{2} \right)$$

$$\Rightarrow \frac{(n-1)S^2}{2} | \underline{x} \sim \chi_{(n)}^2$$

$$\rightarrow \pi(\theta | \underline{x}) = \int_0^{+\infty} \pi(\theta, \phi | \underline{x}) d\phi$$

$$\lambda^* = \frac{1}{2} [n(\bar{\theta} - \lambda)^2 + (n-1)S^2]$$

$$\propto \int_0^{+\infty} \frac{1}{\phi^{\frac{n+1}{2} + 1}} \exp \left\{ -\frac{1}{\phi} \lambda^* \right\} d\phi$$

GAMMA-INVERTIDA

$$\propto \left(1 + \frac{z^2}{n} \right)^{-\frac{n+1}{2}}$$

$$\forall z \in \mathbb{R} \text{ donde } z = \sqrt{n} \frac{(\bar{\theta} - \lambda)}{S}$$

$$\Rightarrow z | \underline{x} \sim t_{(n)}$$

→ APRIORI CON EL METODO DE LAS CONJUGADAS

$$\text{apriori } (\theta, \phi) \sim NG\alpha I(m, c, a, b)$$

$$\pi(\theta, \phi | \underline{x}) \propto \phi^{-\frac{n}{2}} \exp \left\{ -\frac{(n-1)S^2}{2\phi} \right\} \exp \left\{ -\frac{n(\bar{\theta} - \lambda)^2}{2\phi} \right\}$$

$$\cdot \phi^{-(a+1)} \exp \left\{ -\frac{b}{\phi} \right\} \cdot \phi^{-\frac{1}{2}} \exp \left\{ -\frac{(\theta - m)^2}{2c} \right\}$$

$$\mathcal{L} \propto \exp \left\{ -\frac{(n-1)S^2 + 2b}{2\sigma^2} \right\} \sigma^{-\frac{n}{2}}.$$

$$\exp \left\{ - \left(\theta^2 \left(\frac{n}{2\sigma^2} + \frac{1}{2c} \right) - 2\theta \left(\frac{n\bar{x}}{2\sigma^2} + \frac{m}{2c} \right) \right) \right\}$$

$$\Rightarrow (\theta, \sigma^2) | \underline{x} \sim N(\sigma^2) \left(\frac{n\bar{x} + m}{nc + 1}, \dots \right)$$

3) INFERENCIA PARA MODELOS MULTIPARAMETR.

X_1, \dots, X_m v.d. t.q. X_i : frecuencia de la catég. i
 L q. total de observaciones fijo, $N = \sum_{i=1}^m x_i$

probabilidades para categorias: $\underline{\theta} = (\theta_1, \dots, \theta_m)$, $\theta_i \in (0, 1)$

$$\sum_i \theta_i = 1$$

distr. de prob. de (X_1, \dots, X_m) :

$$P(X_1=x_1, \dots, X_m=x_m | \underline{\theta}) = \frac{N!}{\prod_{i=1}^m x_i!} \prod_{i=1}^m \theta_i^{x_i}$$

obs: $m=2$: $P(X_1=x_1, X_2=x_2 | \theta_1, \theta_2) = \frac{(x_1+x_2)!}{x_1! x_2!} \theta_1^{x_1} \theta_2^{x_2}$
 L Beta-Binomial

apriori de Jeffrey:

$$\begin{aligned}
 f(\underline{x} | \underline{\theta}) &\rightarrow \ln f(\underline{x} | \underline{\theta}) = \ln(N!) - \sum_{i=1}^m \ln(x_i!) + \sum_{i=1}^m x_i \ln \theta_i \\
 &\rightarrow \frac{\partial}{\partial \theta_i} \ln f(\underline{x} | \underline{\theta}) = \frac{x_i}{\theta_i}, \quad \frac{\partial^2}{\partial \theta_i^2} \ln f(\underline{x} | \underline{\theta}) = -\frac{x_i}{\theta_i^2} \\
 &\rightarrow \frac{\partial^2}{\partial \theta_i \partial \theta_j} \ln f(\underline{x} | \underline{\theta}) = 0 \\
 &= \Rightarrow \mathbb{E}\left[-\frac{\partial^2}{\partial \theta_i^2} \ln f(\underline{x} | \underline{\theta})\right] = \mathbb{E}\left[\frac{x_i}{\theta_i^2}\right] \stackrel{?}{=} \frac{N}{\theta_i} \\
 &\qquad\qquad\qquad \text{X}_i \sim \text{Bin}(N, \theta_i)
 \end{aligned}$$

$$\Rightarrow \det I(\theta_1, \dots, \theta_m) = \prod_{i=1}^m \frac{N}{\theta_i}$$

$$\Rightarrow \pi(\theta_1, \dots, \theta_m) \propto \prod_{i=1}^m \theta_i^{-1/2}$$

es decir $\underline{\theta} \sim D_i\left(\frac{1}{2}, \dots, \frac{1}{2}\right)$

Primeri conjugado: $\underline{\theta} \sim D_i(\alpha_1, \dots, \alpha_m)$

De hecho, la posteriori se calcula como

$$\pi(\underline{\theta} | \underline{x}) \propto \prod_{i=1}^m \theta_i^{x_i} \cdot \prod_{i=1}^m \theta_i^{\alpha_i - 1}$$

$$\Rightarrow \underline{\theta} | \underline{x} \sim D_i(x_1 + \alpha_1, \dots, x_m + \alpha_m)$$

TABLAS DE CONTINGENCIA

sin perdida de generalidad
estudiaremos el caso de tablas
 2×2

Des variables cualitativas (X, Y), cada una con dos modalidades

→ desde una muestra de tamaño n se observan las frecuencias de cada caso

n_{ij} : n° abs. de x_i conjunta a $y_j \quad \forall i, j = 1, 2$

$\theta_{ij} := P(X = x_i, Y = y_j) \quad \forall i, j$

Objetivo: Establecer si existe independencia entre X e Y

$$\left\{ \begin{array}{l} H_0: M_D \rightarrow \text{no independencia} \\ H_1: M_I \rightarrow \text{independencia} \end{array} \right.$$

$$\hookrightarrow FB_{01} = \frac{P(\underline{x} | M_D)}{P(\underline{x} | M_I)}$$

Tabla de contingencia:

	y_1	y_2
x_1	θ_{11}	θ_{12}
x_2	θ_{21}	θ_{22}

$$\textcircled{H} = \left\{ (\theta_{ij})_{ij} \mid q. \theta_{ij} > 0 \quad \sum \theta_{ij} = 1 \right\}$$

$$\text{apriori: } \underline{\theta} \sim D_i(1, 1, 1, 1)$$

(4) MODELO NO-INDEPENDENCIA

$$\begin{aligned} P(\underline{x} | M_D) &= \int_{\textcircled{H}} \underbrace{P(\underline{x} | \underline{\theta}, M_D) P(\underline{\theta} | M_D)}_{\frac{n!}{\prod n_{ij}!} \prod_{ij} \theta_{ij}^{n_{ij}}} d\underline{\theta} \\ &= \int_{\textcircled{H}} \frac{n!}{\prod n_{ij}!} \prod_{ij} \theta_{ij}^{n_{ij}} \frac{1}{D_i(n_{11}+1, \dots, n_{22}+1)} d\underline{\theta} = \frac{n!}{\prod n_{ij}!} \frac{D_i(n_{11}+1, \dots, n_{22}+1)}{D_i(1, 1, 1, 1)} \end{aligned}$$

(2) MODELO DE INDEPENDENCIA

restriccion de indep. : $\theta_{ij} = \theta_{i+} \theta_{j+} \quad \forall i, j$

$$(\theta_{i+} = \theta_{i1} + \theta_{i2})$$

$$\Rightarrow P(\underline{x} | \underline{\theta}, M_I) = \frac{n!}{\prod h_{ij}!} \theta_{1+}^{n_{1+}} \theta_{2+}^{n_{2+}} \theta_{+1}^{n_{+1}} \theta_{+2}^{n_{+2}}$$

priori se hace : $P(\underline{\theta}_+ | M_I) = \frac{1}{D_{(1,1)}} \cdot \frac{1}{D_{(1,1)}} I_{\Theta_+}(\underline{\theta}_+)$

$$\Rightarrow P(\underline{x} | M_D) = \frac{n!}{\prod h_{ij}!} \cdot \frac{D_i(n_{1+}+1, n_{2+}+1) D_i(n_{+1}+1, n_{+2}+1)}{D_i(1,1) D_i(1,1)}$$